Analiza Danych Ankietowych

Raport

Autorzy: Wiktor Niedźwiedzki, Dawid Skowroński

33 grudnia 2026 Anno Domini

Spis treści

1 Lista 1 **3**

1.1 Zadanie 1 3

1.2 Zadanie 2 4

2 Lista 2 **5**

2.1 Zadanie 1 5

2.2 Zadanie 2 5

Spis wykresów

Spis tabel

1 Charakterystyka zmiennych w zbiorze danych SuicideChina 4

1 Lista 1

Lista 1. stanowi wprowadzenie do pracy związanej z analizą danych ankietowych. Jej celem jest wybór odpowiedniego zbioru danych, który zostanie wykorzystany w dalszych analizach statystycznych.

1.1 Zadanie 1

Zadanie polega na wyborze odpowiedniego zbioru danych do dalszej analizy. Wybrano zbiór `SuicideChina`, dostępny w bibliotece `Stat2Data` w języku R.

Następnie zbiór danych został poddany wstępnemu przetwarzaniu w celu przygotowania go do dalszych analiz. Usunięto zmienne nieprzydatne w analizie, takie jak identyfikator osoby (`Person_ID`), rok (`Year`) i miesiąc (`Month`). Odfiltrowano również obserwacje zawierające niesprecyzowane lub niepożądane wartości w wybranych zmiennych, m.in. `Urban`, `Education`, `Occupation` i `method`.

Ponadto zmienne `Hospitalised` i `Died`, pierwotnie zapisane jako wartości tekstowe „yes” i „no”, przekodowano na wartości binarne 1 i 0, a następnie przekształcono w zmienne kategorialne o dwóch poziomach. W zmiennej `method` wartości z kategorią „Poison unspec” zastąpiono kategorią „Other poison”. Zmienną `Education` przekształcono w zmienną porządkową, uwzględniając kolejność poziomów wykształcenia.

Wprowadzone zmiany miały na celu uporządkowanie danych, ujednolicenie sposobu kodowania wybranych zmiennych oraz przygotowanie zbioru do dalszej analizy statystycznej.

W poniższym bloku kodu przedstawiono sposób przetworzenia i modyfikacji zbioru danych `SuicideChina`:

```
data(SuicideChina)

SuicideChina <- SuicideChina |>
  select(-Person_ID, -Year, -Month) |>
  mutate(
    Education = recode(Education, "iliterate" = "illiterate")
  ) |>
  filter(
    Urban != "unknown",
    Education != "unknown",
    Occupation != "others/unknown",
    Occupation != "others",
    method != "Others",
    method != "unspecified"
  ) |>
  mutate(
    Hospitalised = recode(Hospitalised, "yes" = 1L, "no" = 0L),
    Died = recode(Died, "yes" = 1L, "no" = 0L),
    method = recode(method, "Poison unspec" = "Other poison"),
    Education = factor(
      Education,
```

```
      levels = c("illiterate", "primary", "Secondary", "Tertiary"),
      ordered = TRUE
    )
  ) |>
  mutate(
    across(where(is.factor), droplevels)
  )
```

1.2 Zadanie 2

Oryginalne dane pochodzą z badania opisanego w artykule:

Sun J., Guo X., Zhang J., Wang M., Jia C., Xu A. (2015). „Incidence and fatality of serious suicide attempts in a predominantly rural population in Shandong, China: a public health surveillance study". *BMJ Open*, 5(2), e006762. https://doi.org/10.1136/bmjopen-2014-006762.

Jak wskazują autorzy, dane zebrano z baz danych dotyczących zgonów samobójczych oraz hospitalizacji związanych z próbami samobójczymi w trzech wybranych powiatach prowincji Shandong w Chinach. Przypadki identyfikowano na podstawie pierwotnej przyczyny zgonu lub głównego rozpoznania medycznego, stosując 10. rewizję Międzynarodowej Klasyfikacji Chorób (ICD-10). Rekordy zostały zweryfikowane w celu wykrycia duplikatów, a dane dotyczące tych samych zdarzeń, występujące w obu bazach, powiązano na podstawie imienia i nazwiska, płci, miejsca zamieszkania oraz czasu zdarzenia.

Następnie dane dotyczące zgonów i hospitalizacji połączono w jeden zbiór obejmujący informacje o metodzie próby samobójczej, dacie zdarzenia, jego skutku oraz cechach demograficznych osób. Zastosowano również klasyfikację metod prób samobójczych, uwzględniając m.in. zatrucia pestycydami i innymi substancjami, powieszenie, utonięcie, samookaleczenie ostrym narzędziem oraz skok z wysokości. Ostatecznie zbiór źródłowy obejmował 2571 osób.

Po przeprowadzeniu wstępnego przetwarzania zbiór `SuicideChina` zawiera 2286 obserwacji i 8 zmiennych. Zmienne opisują m.in. wiek i płeć osób, poziom ich wykształcenia, kategorię zawodową, miejsce zamieszkania, hospitalizację, zgon oraz metodę podjęcia próby samobójczej.

W tabeli przedstawiono nazwy zmiennych, ich znaczenie, typ statystyczny oraz przykładowe wartości.

Tabela 1: Charakterystyka zmiennych w zbiorze danych SuicideChina

Zmienna	Opis	Typ	Przykładowe wartości
Hospitalised	Informacja o hospitalizacji osoby	Binarna, nominalna	0, 1
Died	Informacja o zgonie osoby	Binarna, nominalna	0, 1
Urban	Informacja o zamieszkaniu na obszarze miejskim	Binarna, nominalna	no, yes
Sex	Płeć osoby	Binarna, nominalna	female, male

Zmienna	Opis	Typ	Przykładowe wartości
Age	Wiek osoby wyrażony w latach	Ilościowa, dyskretna	39, 83, 60
Education	Poziom wykształcenia	Jakościowa, porządkowa	Secondary, Tertiary
Occupation	Kategoria zawodowa osoby	Jakościowa, nominalna	farming, household
method	Metoda podjęcia próby samobójczej	Jakościowa, nominalna	Cutting, Hanging

Źródło: Opracowanie własne na podstawie zbioru danych `SuicideChina` z pakietu `Stat2Data` oraz opis danych w pakiecie.

Zmienna `Education` ma charakter porządkowy, ponieważ jej kategorie można uporządkować od najniższego do najwyższego poziomu wykształcenia: `illiterate`, `primary`, `Secondary`, `Tertiary`. Zmienne `Urban`, `Sex`, `Occupation` i `method` są nominalne, ponieważ ich kategorie nie mają naturalnej kolejności. Zmienna `Age` jest ilościowa i w analizowanym zbiorze przyjmuje wartości w pełnych latach, dlatego można ją traktować jako dyskretną.

2 Lista 2

kotek

2.1 Zadanie 1

kotek

2.2 Zadanie 2

kotek