Analiza Danych Ankietowych

Raport

Autorzy: Wiktor Niedźwiedzki, Dawid Skowroński

33 grudnia 2026 Anno Domini

Spis treści

1 Lista 1 **3**

1.1 Zadanie 1 . . . 3

1.2 Zadanie 2 . . . 3

2 Lista 2 **5**

2.1 Zadanie 1 . . . 5

2.2 Zadanie 2 . . . 12

3 Lista 3 **12**

3.1 Zadanie 1 . . . 12

3.2 Zadanie 2 . . . 13

3.3 Zadanie 3 . . . 13

Spis wykresów

1 Liczności płci . . . 7

2 Liczności zawodów . . . 7

3 Liczności metod . . . 8

4 Liczności wykształcenia . . . 8

5 Mozaika płeć vs zawód . . . 9

6 Mozaika płeć vs metoda . . . 9

7 Mozaika płeć vs wykształcenie . . . 10

8 Mozaika zawód vs metoda . . . 10

9 Mozaika zawód vs wykształcenie . . . 11

10 Mozaika metoda vs wykształcenie . . . 11

Spis tabel

1 Charakterystyka zmiennych w zbiorze danych . . . 4

2 Liczność i częstość dla zmiennej Plec . . . 5

3 Liczność i częstość dla zmiennej Zawód . . . 5

4 Liczność i częstość dla zmiennej Metoda . . . 6

5 Liczność i częstość dla zmiennej Wykształcenie . . . 6

6 Realizacja 95-procentowych przedziały ufności dla prawdopodobieństwa sukcesu metodą Cloppera-Pearsona . . . 12

7 Porównanie estymatorów prawdopodobieństwa sukcesu na podstawie symulacji . 12

1 Lista 1

Lista 1. stanowi wprowadzenie do pracy związanej z analizą danych ankietowych. Jej celem jest wybór odpowiedniego zbioru danych, który zostanie wykorzystany w dalszych analizach statystycznych.

1.1 Zadanie 1

Zadanie polega na wyborze odpowiedniego zbioru danych do dalszej analizy. Wybrano zbiór `SuicideChina`, dostępny w bibliotece `Stat2Data` w języku R.

Zbiór danych został poddany wstępnemu przetwarzaniu w celu przygotowania go do dalszych analiz. Usunięto zmienne nieprzydatne w analizie, takie jak identyfikator osoby (`Person_ID`), rok (`Year`) i miesiąc (`Month`). Następnie przetłumaczono nazwy zmiennych oraz wartości kategorii na język polski, aby ułatwić interpretację danych i zachować spójność językową analizy. Zmieniono nazwy kolumn na `Hospitalizowano`, `Zgon`, `Miasto`, `Plec`, `Wiek`, `Wyksztalcenie`, `Zawod` i `Metoda`. Odfiltrowano obserwacje zawierające niesprecyzowane lub niepożądane wartości w zmiennych `Miasto`, `Wyksztalcenie`, `Zawod` i `Metoda`. Zmienne binarne w `Hospitalizowano`, `Zgon` oraz `Miasto` przekonwertowano na wartości binarne 1 oraz 0. W zmiennej `Metoda` wartości z kategorią „Niesprecyzowana trucizna" zastąpiono kategorią „Inna trucizja". Zmienną `Wykształcenie` przekształcono w zmienną porządkową, uwzględniając kolejność poziomów wykształcenia.

Wprowadzone zmiany miały na celu poprawę czytelności i jakości danych, ujednolicenie sposobu kodowania zmiennych oraz przygotowanie zbioru do dalszej analizy statystycznej.

1.2 Zadanie 2

Oryginalne dane pochodzą z badania opisanego w artykule:

Sun J., Guo X., Zhang J., Wang M., Jia C., Xu A. (2015). „Incidence and fatality of serious suicide attempts in a predominantly rural population in Shandong, China: a public health surveillance study". *BMJ Open*, 5(2), e006762. https://doi.org/10.1136/bmjopen-2014-006762.

Jak wskazują autorzy, dane zebrano z baz danych dotyczących zgonów samobójczych oraz hospitalizacji związanych z próbami samobójczymi w trzech wybranych powiatach prowincji Shandong w Chinach. Przypadki identyfikowano na podstawie pierwotnej przyczyny zgonu lub głównego rozpoznania medycznego, stosując 10. rewizję Międzynarodowej Klasyfikacji Chorób (ICD-10). Rekordy zostały zweryfikowane w celu wykrycia duplikatów, a dane dotyczące tych samych zdarzeń, występujące w obu bazach, powiązano na podstawie imienia i nazwiska, płci, miejsca zamieszkania oraz czasu zdarzenia.

Następnie dane dotyczące zgonów i hospitalizacji połączono w jeden zbiór obejmujący informacje o metodzie próby samobójczej, dacie zdarzenia, jego skutku oraz cechach demograficznych osób. Zastosowano również klasyfikację metod prób samobójczych, uwzględniając m.in. zatrucia pestycydami i innymi substancjami, powieszenie, utonięcie, samookaleczenie ostrym narzędziem oraz skok z wysokości. Ostatecznie zbiór źródłowy obejmował 2571 osób.

Po przeprowadzeniu wstępnego przetwarzania opisanego w Zadaniu 1. zbiór `SuicideChina` zawiera 2286 obserwacji i 8 zmiennych. Zmienne opisują m.in. wiek i płeć osób, poziom ich

wykształcenia, kategorię zawodową, miejsce zamieszkania, informację o hospitalizacji , zgonie oraz metodę podjęcia próby samobójczej.

W tabeli przedstawiono nazwy zmiennych, ich znaczenie, typ statystyczny oraz przykładowe wartości.

Tabela 1: Charakterystyka zmiennych w zbiorze danych

Zmienna	Opis	Typ	Przykładowe wartości
Hospitalizowana	Informacja o hospitalizacji osoby	Binarna	0, 1
Zgon	Informacja o zgonie osoby	Binarna	0, 1
Miasto	Informacja o zamieszkaniu na obszarze miejskim	Binarna	0 (obszar wiejski), 1 (obszar miejski)
Płeć	Płeć osoby	Nominalna	kobieta, mężczyzna
Wiek	Wiek osoby wyrażony w latach	Dyskretna	39, 83, 60
Wykształcenie	Poziom wykształcenia	Porządkowa	niepiśmienny, podstawowe, średnie, wyższe
Zawód	Kategoria zawodowa osoby	Nominalna	rolnictwo, gospodarstwo domowe
Metoda	Metoda podjęcia próby samobójczej	Nominalna	podcięcie, powieszenie

Źródło: Opracowanie własne na podstawie zbioru danych `SuicideChina` z pakietu `Stat2Data` oraz opis danych w pakiecie.

Zmienna `Wyksztalcenie` ma charakter porządkowy, ponieważ jej kategorie można uporządkować od najniższego do najwyższego poziomu wykształcenia: `niepismienny`, `podstawowe`, `średnie`, `wyższe`. Zmienne `Plec`, `Zawod` i `Metoda` są zmiennymi nominalnymi. Zmienna `Wiek` jest zmienną ilościową dyskretną.

- `Hospitalizowany` – określa, czy osoba w wyniku próby samobójczej została hospitalizowana (1), czy nie (0).
- `Zgon` – określa, czy próba samobójcza zakończyła się zgonem osoby (1), czy przeżyła ona próbę (0).
- `Miasto` – określa miejsce zamieszkania osoby: miasto (1) lub wieś (0).
- `Plec` – określa płeć osoby: kobieta lub mężczyzna.
- `Wiek` – określa wiek osoby wyrażony w pełnych latach.
- `Wyksztalcenie` – określa najwyższy uzyskany poziom wykształcenia osoby. Wyróżniono następujące kategorie: `niepismienny`, `podstawowe`, `średnie` oraz `wyższe`.
- `Zawod` – określa kategorię zawodową osoby. Wyróżniono następujące kategorie: handel i usługi, rolnictwo, gospodarstwo domowe (osoby zajmujące się prowadzeniem domu, np. gospodynie domowe), wolny zawód (np. lekarz, prawnik), emeryt, uczeń/student, bezrobotny oraz robotnik.
- `Metoda` – określa metodę podjęcia próby samobójczej. Wyróżniono następujące kategorie:
  - `podcięcie` – podcięcie żył;
  - `utonięcie` – próba samobójcza poprzez utonięcie;
  - `powieszenie` – powieszenie, bez sprecyzowania, czy śmierć nastąpiła wskutek uduszenia, czy uszkodzenia rdzenia kręgowego.

- `skok` – upadek z wysokości;
- `pestycyd` – zatrucie pestycydami, czyli substancjami szeroko stosowanymi w rolnictwie do zwalczania szkodników;
- `inna trucizna` – zatrucie substancją toksyczną inną niż pestycyd.

2 Lista 2

Lista polega na przedstawieniu liczebności i częstości występowania poszczególnych kategorii zmiennych nominalnych i porządkowych, zilustrowaniu ich na wykresach oraz analizie zależności między parami zmiennych za pomocą wykresów mozaikowych. Dodatkowo należy wyznaczyć 95-procentowy przedział ufności dla prawdopodobieństwa sukcesu wybranej zmiennej binarnej.

2.1 Zadanie 1

Celem zadania jest przeprowadzenie analizy wybranych zmiennych nominalnych i porządkowych ze zbioru danych poprzez sporządzenie tabel liczności i częstości, wizualizację ich rozkładów za pomocą wykresów słupkowych lub kołowych oraz analizę zależności między parami zmiennych z wykorzystaniem wykresów mozaikowych.

2.1.1 Zadanie 1a

Do zmiennych nominalnych należą: `Plec`, `Zawod` oraz `Metoda`. Zmienna `Wyksztalcenie` określa poziom wykształcenia. Jej kategorie mają naturalną kolejność.

kotek

Tabela 2: Liczność i częstość dla zmiennej Plec

Kategoria	Liczność	Częstość [%]
kobieta	1184	51.79
mężczyzna	1102	48.21

Źródło: Opracowanie własne.

kotek

Tabela 3: Liczność i częstość dla zmiennej Zawód

Kategoria	Liczność	Częstość [%]
handel/usługi	16	0.70
rolnictwo	1934	84.60
gospodarstwo domowe	239	10.45
wolny zawód	33	1.44
emeryt	1	0.04
uczeń/student	33	1.44
bezrobotny	24	1.05

Kategoria	Liczność	Częstość [%]
robotnik	6	0.26

Źródło: Opracowanie własne.

kotek

Tabela 4: Liczność i częstość dla zmiennej Metoda

Kategoria	Liczność	Częstość [%]
podcięcie	25	1.09
utonięcie	26	1.14
powieszenie	419	18.33
skok	12	0.52
inna trucizna	160	7.00
pestycyd	1644	71.92

Źródło: Opracowanie własne.

kotek

Tabela 5: Liczność i częstość dla zmiennej Wyksztalcenie

Kategoria	Liczność	Częstość [%]
niepiśmienny	520	22.75
podstawowe	632	27.65
średnie	1119	48.95
wyższe	15	0.66

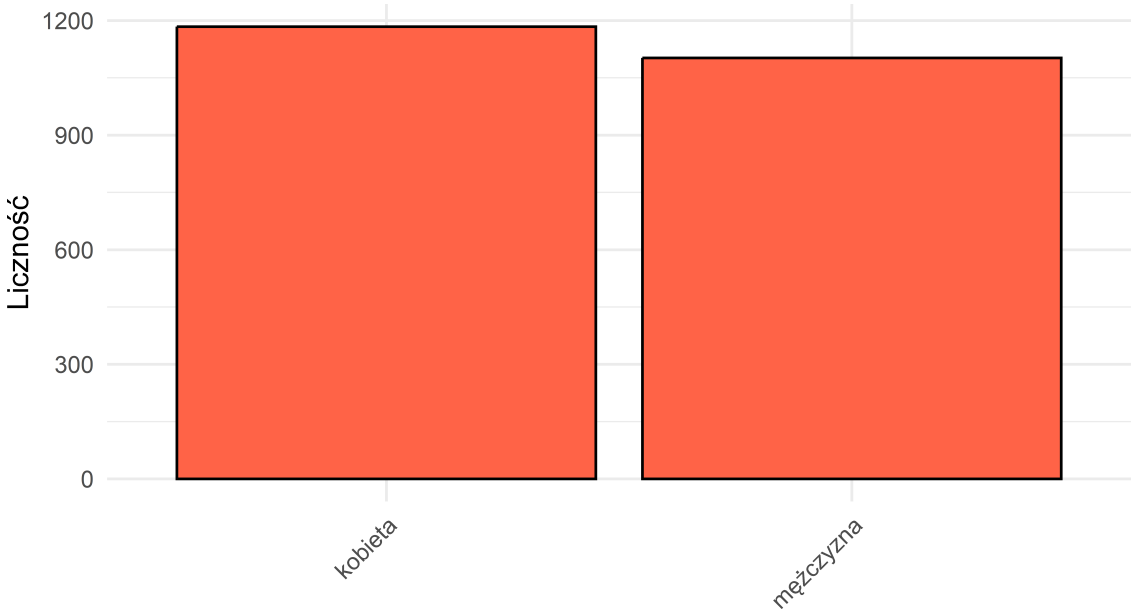
Źródło: Opracowanie własne.

kotek

2.1.2 Zadanie 1b

kotek

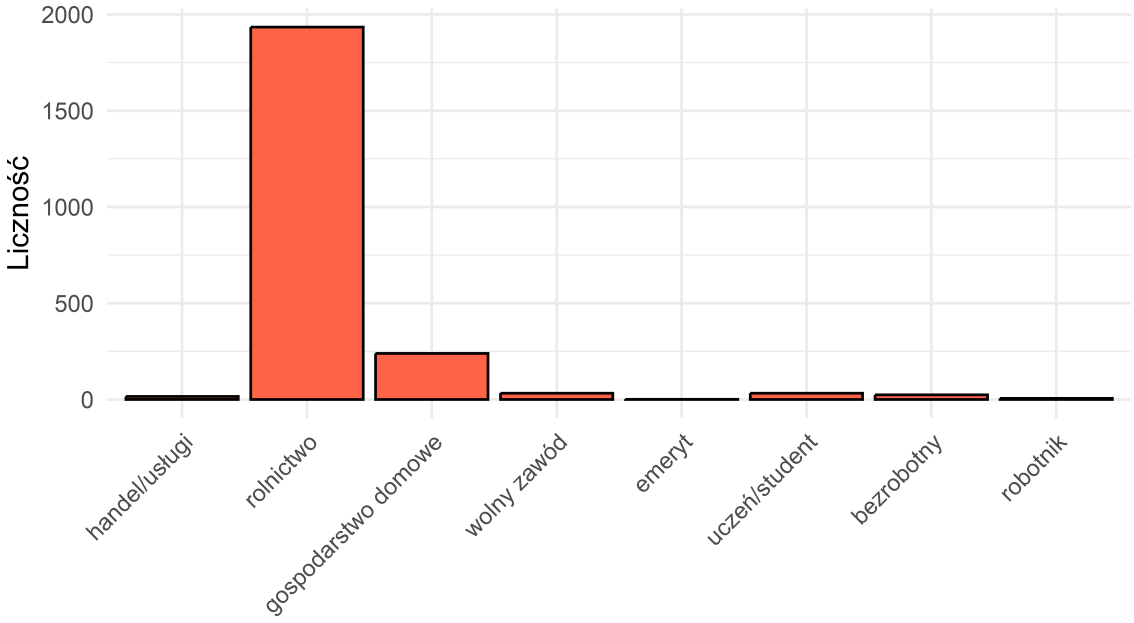
kotek



Wykres 1: Liczności płci

Źródło: Opracowanie własne.

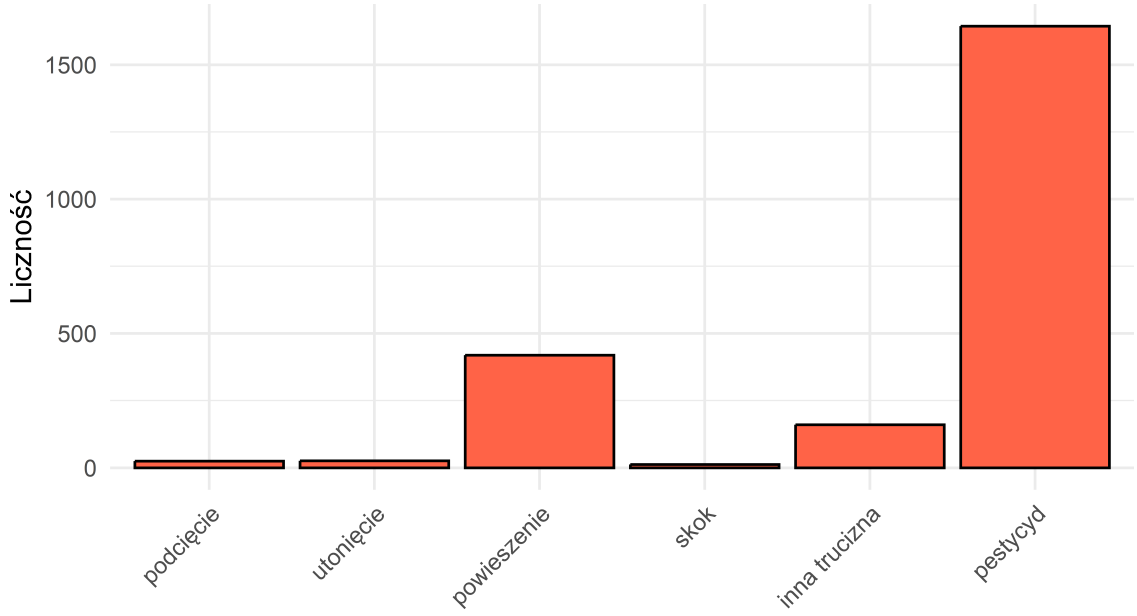
kotek



Wykres 2: Liczności zawodów

Źródło: Opracowanie własne.

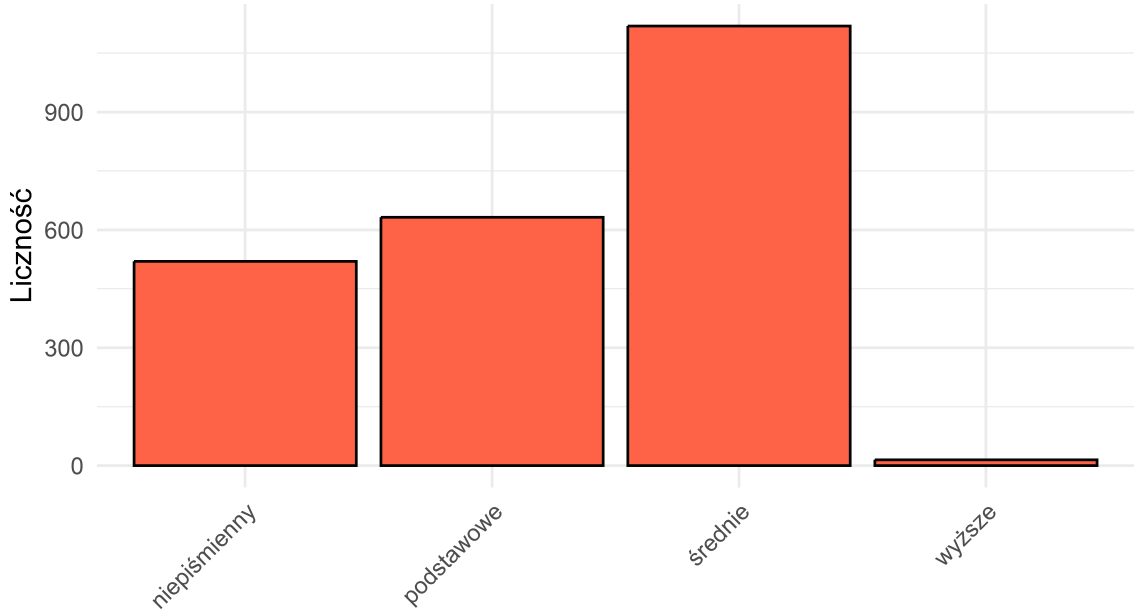
kotek



Wykres 3: Liczności metod

Źródło: Opracowanie własne.

kotek



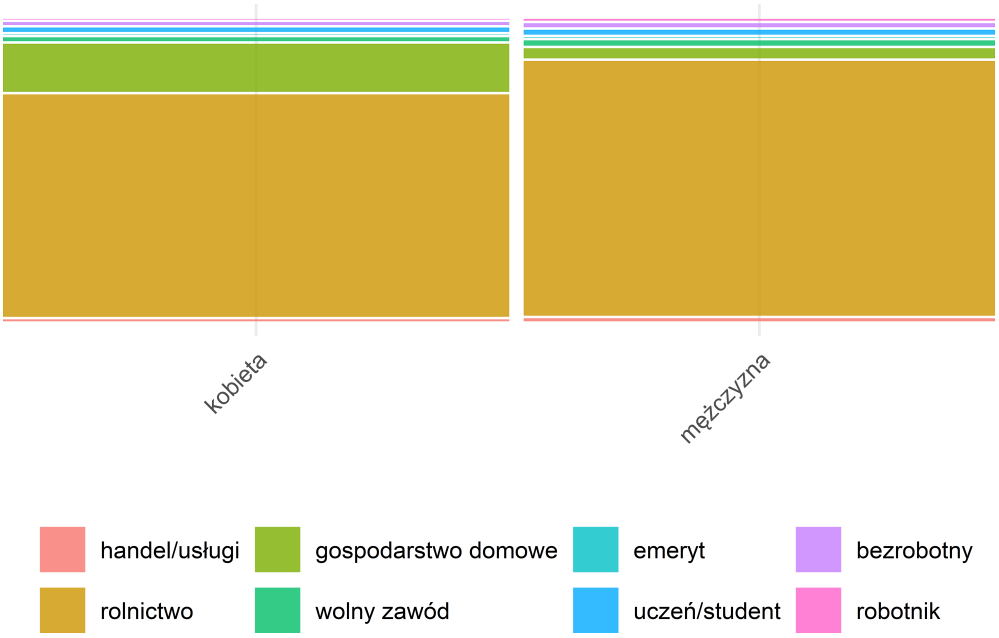
Wykres 4: Liczności wykształcenia

Źródło: Opracowanie własne.

kotek

2.1.3 Zadanie 1c

kotek



Wykres 5: Mozaika płeć vs zawód

Źródło: Opracowanie własne.

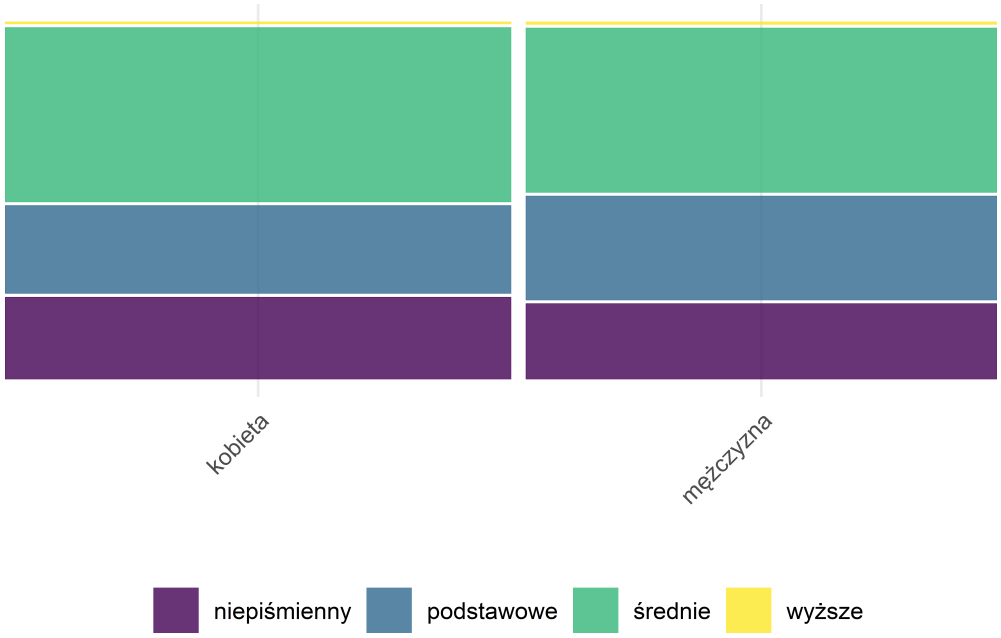
kotek



Wykres 6: Mozaika płeć vs metoda

Źródło: Opracowanie własne.

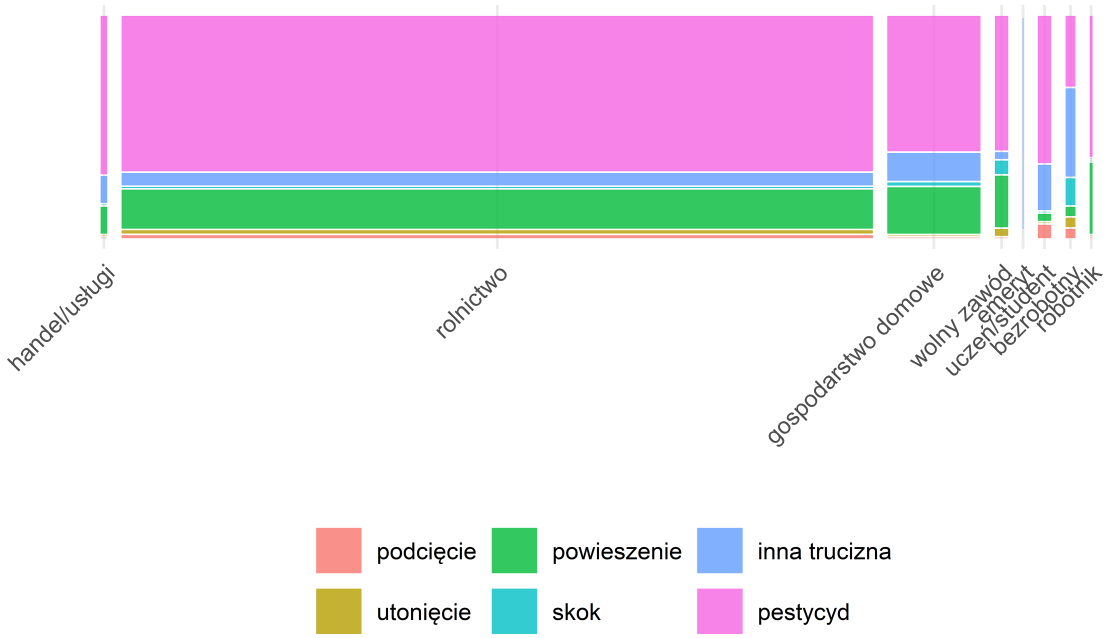
kotek



Wykres 7: Mozaika płeć vs wykształcenie

Źródło: Opracowanie własne.

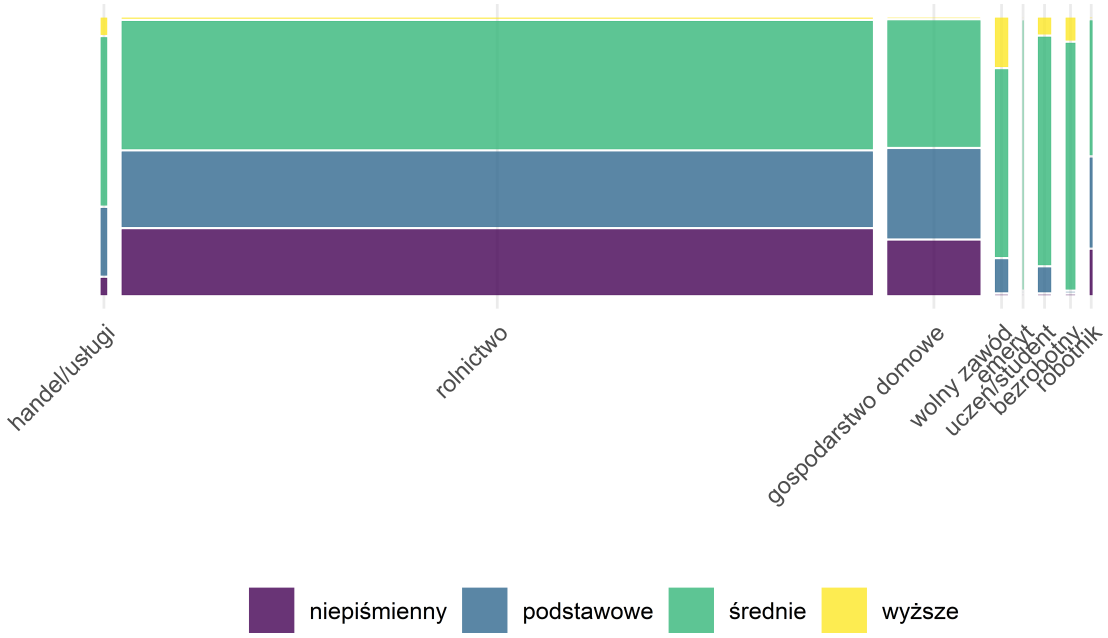
kotek



Wykres 8: Mozaika zawód vs metoda

Źródło: Opracowanie własne.

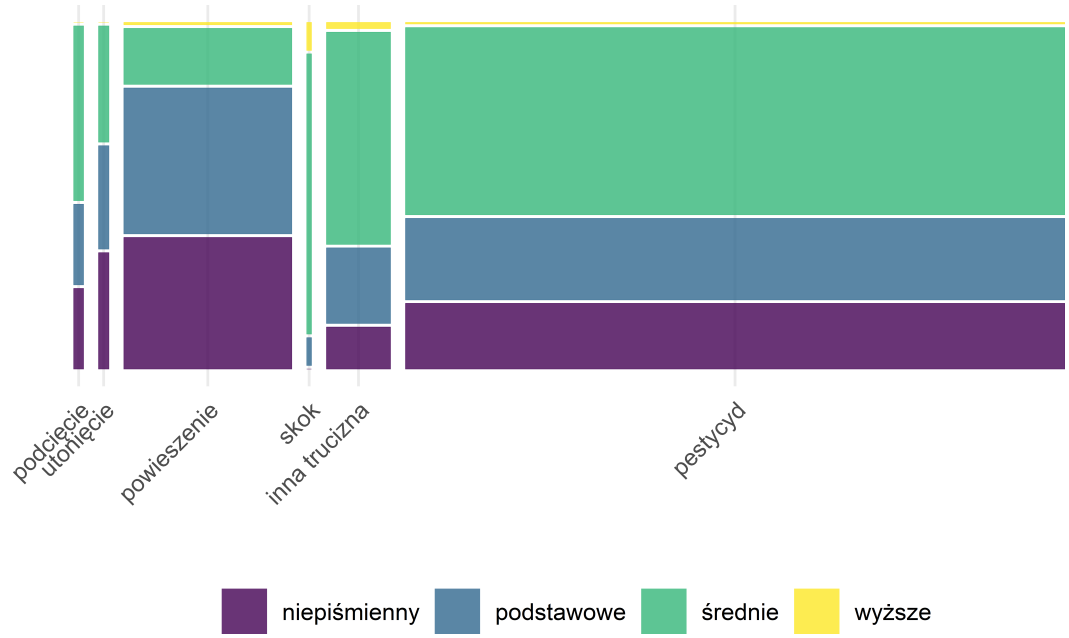
kotek



Wykres 9: Mozaika zawód vs wykształcenie

Źródło: Opracowanie własne.

kotek



Wykres 10: Mozaika metoda vs wykształcenie

Źródło: Opracowanie własne.

kotek

2.2 Zadanie 2

Celem zadania jest wyznaczenie realizacja 95-procentowego przedziału ufności dla prawdopodobieństwa wystąpienia jednej z dwóch wartości (sukcesu) wybranej zmiennej binarnej.

Na podstawie przeprowadzonych symulacji stwierdzono, że dla liczności próby odpowiadającej analizowanemu zbiorowi danych metoda Cloppera-Pearsona zapewnia najwyższe prawdopodobieństwo pokrycia oraz najwęższe przedziały ufności. W związku z tym metodę tę wykorzystano w dalszej analizie.

Przyjęto, że sukcesem jest wystąpienie zgonu osoby w wyniku próby samobójczej lub jej hospitalizacja. W związku z tym wartość 1 w obu zmiennych oznacza sukces, natomiast wartość 0 – jego brak.

Tabela 6: Realizacja 95-procentowych przedziały ufności dla prawdopodobieństwa sukcesu metodą Cloppera-Pearsona

Zmienna	Prawdopodobieństwo	Dolna.granica	Górna.granica
Zgon	0.5376	0.5169	0.5582
Hospitalizowano	0.5612	0.5406	0.5817

Źródło: Opracowanie własne.

kotek

3 Lista 3

Lista polega na porównaniu dwóch estymatorów prawdopodobieństwa sukcesu za pomocą symulacji, ocenie ich obciążenia i błędów średniokwadratowych, a także przeprowadzeniu testów statystycznych dotyczących pojedynczego prawdopodobieństwa sukcesu oraz równości dwóch prawdopodobieństw sukcesu.

3.1 Zadanie 1

Zadanie polega na porównaniu dwóch estymatorów prawdopodobieństwa sukcesu w mechanizmie odpowiedzi losowej za pomocą symulacji. Należy zbadać ich obciążenie i błędy średniokwadratowe dla różnych wartości parametrów π, q i liczebności próby n, a następnie porównać wyniki symulacyjne z wartościami teoretycznymi.

Przeprowadzono symulację obejmującą 100 000 prób dla następujących wartości parametrów: $\pi \in \{0.2, 0.5, 0.8\}$, $q \in \{0.3, 0.7, 0.9\}$ oraz $n \in \{10, 50, 100, 1000\}$. Wyniki symulacji przedstawiono w tabeli poniżej.

Tabela 7: Porównanie estymatorów prawdopodobieństwa sukcesu na podstawie symulacji

π	q	n	$Bias(\hat{\pi})$	$Bias(\tilde{\pi})$	$MSE(\hat{\pi})$	$MSE(\tilde{\pi})$	$Bias_{teor}(\hat{\pi})$	$MSE_{teor}(\hat{\pi})$
0.2	0.3	10	-0.0004	0.0646	0.1469	0.0888	0	0.1472

π	q	n	$Bias(\hat{\pi})$	$Bias(\tilde{\pi})$	$MSE(\hat{\pi})$	$MSE(\tilde{\pi})$	$Bias_{teor}(\hat{\pi})$	$MSE_{teor}(\hat{\pi})$
0.2	0.3	50	-0.0005	0.0089	0.0294	0.0243	0	0.0294
0.2	0.3	100	0.0001	0.0023	0.0147	0.0136	0	0.0147
0.2	0.3	1000	0.0000	0.0000	0.0015	0.0015	0	0.0015
0.2	0.7	10	0.0019	0.0663	0.1472	0.0898	0	0.1473
0.2	0.7	50	0.0004	0.0099	0.0295	0.0243	0	0.0295
0.2	0.7	100	-0.0004	0.0019	0.0147	0.0136	0	0.0147
0.2	0.7	1000	0.0001	0.0001	0.0015	0.0015	0	0.0015
0.2	0.9	10	0.0000	0.0062	0.0301	0.0269	0	0.0301
0.2	0.9	50	-0.0001	0.0000	0.0060	0.0060	0	0.0060
0.2	0.9	100	0.0001	0.0001	0.0030	0.0030	0	0.0030
0.2	0.9	1000	0.0000	0.0000	0.0003	0.0003	0	0.0003
0.5	0.3	10	-0.0020	-0.0016	0.1560	0.1114	0	0.1562
0.5	0.3	50	0.0003	0.0002	0.0313	0.0311	0	0.0312
0.5	0.3	100	0.0003	0.0003	0.0156	0.0156	0	0.0156
0.5	0.3	1000	0.0002	0.0002	0.0016	0.0016	0	0.0016
0.5	0.7	10	-0.0003	-0.0005	0.1548	0.1112	0	0.1563
0.5	0.7	50	-0.0005	-0.0005	0.0313	0.0311	0	0.0313
0.5	0.7	100	0.0003	0.0003	0.0157	0.0157	0	0.0156
0.5	0.7	1000	0.0002	0.0002	0.0016	0.0016	0	0.0016
0.5	0.9	10	0.0004	0.0004	0.0389	0.0386	0	0.0391
0.5	0.9	50	0.0001	0.0001	0.0078	0.0078	0	0.0078
0.5	0.9	100	-0.0002	-0.0002	0.0039	0.0039	0	0.0039
0.5	0.9	1000	0.0000	0.0000	0.0004	0.0004	0	0.0004
0.8	0.3	10	-0.0003	-0.0652	0.1469	0.0893	0	0.1472
0.8	0.3	50	-0.0005	-0.0101	0.0294	0.0242	0	0.0294
0.8	0.3	100	0.0001	-0.0022	0.0147	0.0136	0	0.0147
0.8	0.3	1000	0.0002	0.0002	0.0015	0.0015	0	0.0015
0.8	0.7	10	0.0014	-0.0640	0.1465	0.0887	0	0.1473
0.8	0.7	50	0.0000	-0.0095	0.0293	0.0242	0	0.0295
0.8	0.7	100	0.0002	-0.0022	0.0148	0.0136	0	0.0147
0.8	0.7	1000	0.0002	0.0002	0.0015	0.0015	0	0.0015
0.8	0.9	10	-0.0002	-0.0064	0.0302	0.0269	0	0.0301
0.8	0.9	50	0.0004	0.0003	0.0060	0.0060	0	0.0060
0.8	0.9	100	0.0001	0.0001	0.0030	0.0030	0	0.0030
0.8	0.9	1000	-0.0001	-0.0001	0.0003	0.0003	0	0.0003

Źródło: Opracowanie własne.

3.2 Zadanie 2

kotek

3.3 Zadanie 3

kotek